

LlamaGen Agent Plugin

产品方案

从 Comic API / MCP 到 ChatGPT 与 Claude Code 原生漫画工作室

内部沟通稿	产品与工程团队	2026-07-24
版本 v1.0	用于方案同步与立项讨论	Asia / Singapore

核心判断

LlamaGen 已有 Agent 可调用的技术底座。下一步的重点不是再造一个 API，而是把现有能力包装成可安装、可授权、可持续编辑、可交付项目的创作代理。

一页结论

这份方案希望团队先统一方向，再进入技术拆解。

建议立项

以现有 llamagen.ai /api/mcp 为统一后端，推出 ChatGPT/Codex 与 Claude Code 两套宿主插件。插件负责理解任务和编排工具，LlamaGen 负责账号、素材、生成、Credits、项目保存、编辑和导出。

用户看到的产品

一句话安装；直接上传剧本、图片或素材；在对话中生成、修改、续写；最后同时拿到成品和可编辑项目。

团队实际建设的系统

一个托管 MCP + OAuth；两套薄插件包装；共享技能；现有 Comic API、生成编排和编辑器继续复用。

需要本次会议拍板的 5 件事

序号	决策	建议方向
01	首发宿主	建议 ChatGPT/Codex 优先，Claude Code 同期准备或紧随其后。
02	MVP 场景	建议只聚焦“故事/剧本转漫画”和“指定面板修改”两条闭环。
03	编辑器落点	确定插件生成后打开哪个现有 LlamaGen 项目编辑界面。
04	账号与计费	OAuth 登录；宿主承担推理用量，LlamaGen Credits 承担生成成本。
05	代码归属	MCP/OAuth/API 由 llamagen.ai 持有；插件建议独立公开仓库。

一句话对外定位：让 ChatGPT 或 Claude 帮你做漫画，LlamaGen 保证角色一致，并让每一格都能继续编辑。

背景说明：ChatCut 给出的信号

ChatCut 的领先点不主要在模型，而在于把复杂编辑器重新包装成 Agent 可以调用、用户可以安装的产品。

观察维度	ChatCut 做法	LlamaGen 机会
安装	首屏只放一条可复制指令，Agent 自动完成安装、登录、验证和新任务创建。	把 API 文档式接入改造成“一句话安装 LlamaGen 漫画工作室”。
架构	一个托管 MCP，Codex 与 Claude Code 使用不同 manifest，但共享技能。	沿用同一 /api/mcp，不为每个宿主复制业务后端。
表达	先展示 talking head、long-to-short、字幕、MG 等任务，再解释能力。	用“小说转漫画、角色一致、分镜、改单格、续写”替代工具清单。
交付	同时返回 Final file 与 Editable project。	同时返回 PDF/图片包与“在 LlamaGen 中继续编辑”链接。
授权	插件通过宿主触发 OAuth，不要求用户复制 API Key。	保留 API Token 给开发者；插件用户走 OAuth。
页面	同一地址对浏览器返回营销页，对 Agent 返回可执行安装指南。	建设 Browser + Agent 双层内容，缩短安装与恢复路径。

值得借鉴

任务优先、单指令安装、OAuth、共享技能、成品和可编辑项目双交付、按宿主分发。

不要照搬

页面过长、两个宿主内容几乎相同、对“无需切换应用”和 Credits 的表达容易产生误解。

参考页面：[chatcut.io/chatgpt-plugin](#)；[chatcut.io/claude-code-plugin](#)；ChatCut Agent Plugin。

LlamaGen 现状与机会缺口

底座已经存在，差距集中在授权、工具深度、项目交付和面向用户的产品包装。

现有资产	当前状态	可复用价值
远程 MCP	https://llamagen.ai/api/mcp	统一 Agent 接入层已经存在。
Server Card	/.well-known/mcp/server-card.json	可被 Agent 和目录发现。
Comic API	生成、状态、用量、REST 文档	提供生产级漫画生成能力。
编辑能力	项目、角色、Storyboard、面板、导出等产品能力	具备“可继续编辑”的潜在闭环。
多产品工作区	Story、Workflow、Manga Editor、generate-server	可复用创作、编排和编辑能力。

四个核心缺口

- 1. API-first，而非任务-first**

当前入口主要解释 endpoint、schema 和 token。普通创作者不知道应该“叫它做什么”。
- 2. Bearer Token，而非 OAuth**

复制 API Key
对开发者可接受，但会显著压低插件用户的安装完成率。
- 3. 生成结果，而非项目闭环**

现有 MCP 主要覆盖创建、状态和用量，尚未把上传、改单格、续写、项目打开、导出串起来。
- 4. 文档跳转，而非可执行 onboarding**

当前“Open in ChatGPT / Claude”更像询问如何调用 API，不等同于安装插件并开始第一次创作。

机会判断

LlamaGen 的差异化不应是“Agent 也能生成图片”，而应是：Agent 能创建并持续修改一个有角色、场景、面板、对白和版本的漫画项目。

产品设计：双宿主、双定位

底层能力共用，但 ChatGPT 与 Claude Code 不应该只是替换 Logo 和产品名。

ChatGPT / Codex：创作者模式

核心用户：漫画作者、教育者、营销人员、普通创作者。
核心承诺：无需写代码，把故事、剧本、图片和角色设定交给 ChatGPT，得到可编辑漫画项目。
首屏文案：让 ChatGPT 帮你做漫画。LlamaGen 保持角色一致，并让每一格都可继续编辑。

Claude Code：生产与自动化模式

核心用户：独立开发者、内容工作室、游戏/教育/电商团队。
核心承诺：从代码库、文件和批处理任务中驱动漫画生产流水线。
首屏文案：把剧本和素材变成可调用、可检查、可继续编辑的漫画生产流程。

MVP 只做两条闭环

工作流	用户路径	战略意义
A. 故事 / 剧本转漫画	上传或粘贴内容 -> 识别角色与场景 -> 生成角色表 -> 生成 Storyboard -> 生成面板 -> 打开编辑项目 -> 导出。	证明从输入到项目交付的完整价值。
B. 指定面板修改	选择项目与面板 -> 修改构图、对白或角色表现 -> 预估 Credits -> 确认 -> 重绘 -> 保存新版本。	证明插件不是一次性生成器，而是持续编辑器。

后续场景池

创作扩展

角色 Bible、Script-to-Storyboard、续写、多页项目、风格模板、对白和气泡编辑。

生产扩展

漫画翻译、本地化排版、批量生成、教育漫画、商品故事、Comic-to-Video。

产品边界

对话宿主是“控制台”，LlamaGen 是“专业工作区”。对外明确承诺：可以在对话里完成大部分操作，也可以随时打开 LlamaGen 对每个面板、对白、角色与版本做精修。

核心体验与交付契约

用户不需要理解 MCP、API Key 或后端编排，只需要看到任务、进度、成本和可编辑结果。



对话负责理解与编排；LlamaGen 负责生成、保存、计费与可编辑项目。

每次任务必须交付的 5 个结果

	交付项	要求
1	任务摘要	说明识别到的目标、素材和约束。
2	执行状态	分步骤显示角色、分镜、面板、导出等进度，失败时提供可恢复动作。
3	生成预览	返回缩略图或资源链接，不让用户只拿到 JSON。
4	成品文件	PDF、PNG/JPG/WEBP 包、ZIP 或视频等最终交付。
5	可编辑项目	明确的“在 LlamaGen 中继续编辑”Deep Link，并保留项目上下文。

建议安装提示词

ChatGPT / Codex

阅读 [llamagen.ai/chatgpt](#)，帮我安装 LlamaGen 插件并创建一个新的漫画任务。

Claude Code

阅读 [llamagen.ai/claude](#)，安装并使用 LlamaGen 插件，把我的剧本或素材创建成可编辑漫画项目。

落地页与分发设计

落地页不仅承担 SEO 和转化，还承担 Agent 可读取的安装与恢复协议。

页面区块	内容要求
1. Hero	宿主名称 + 一句话价值 + 单行安装指令 + 复制按钮。
2. 主演示	对话界面与 LlamaGen 项目并排，展示“成品 + 可编辑项目”。
3. 任务导航	使用 Job-to-be-Done：剧本转漫画、角色一致、Storyboard、改单格、续写。
4. 真实案例	只展示 3 个高质量项目：输入、执行过程、输出、项目链接。
5. 能力与信任	OAuth、隐私、Credits、确认策略、项目所有权、可撤销性。
6. 定价	把 Credits 换算成大致页数/面板数，并区分宿主推理用量。
7. FAQ 与 CTA	回答“是否必须打开 LlamaGen”“素材是否上传”“如何收费”“失败是否扣费”。

双层响应

浏览器访问

返回完整视觉落地页：价值主张、案例、定价、FAQ、复制按钮和结构化 SEO。

Agent 抓取


返回机器可读的安装指南：宿主检测、安装、OAuth、验证、恢复、创建新任务和首个提示词。

首发 URL 建议

/chatgpt-plugin 与 /claude-code-plugin 用于用户与搜索；/chatgpt 与 /claude 用于 Agent 安装指南。页面初期建议归属 llamagen.ai，避免在 Context Base 与主站之间增加新的路由同步成本。

技术路线：一个 MCP，多宿主薄包装

系统设计要把宿主差异限制在插件层，把账号、项目、Credits 和业务逻辑留在权威服务中。



核心原则：一个托管 MCP，多宿主薄包装；API 与数据真相继续由 llamagen.ai 持有。

关键技术决策

决策	要求
OAuth	插件用户走授权登录，不复制 API Key；API Token 继续服务服务器端开发者。
Scopes	按 read_project、write_project、generate、export 等最小权限拆分。
工具响应	返回文本摘要、结构化状态、预览资源和可打开的项目链接。
素材上传	提供受控上传或预签名 URL；避免把大文件或 base64 直接塞进工具参数。
长任务	创建任务后返回 generationId；使用状态查询或通知，不让宿主连接持续阻塞。
Credits	执行前估算；真实生成前确认；失败与重试规则透明。
幂等	所有写工具接受 idempotency key，宿主重试不得重复创建或扣费。
错误	统一 AUTH_REQUIRED、INSUFFICIENT_CREDITS、INVALID_INPUT、GENERATION_FAILED 等结构化错误。

MCP 工具与技能路线

MCP 工具保持原子、稳定、可审计；技能负责把多个工具编排成用户任务。

优先级	工具	动作	说明
P0	search_llamagen_docs	保留	查找能力、限制、错误与帮助。
P0	create_project	新增	先创建可持久化项目，不直接生成孤立文件。
P0	upload_reference	新增	上传剧本、图片、角色和场景素材。
P0	create_comic_generation	增强	绑定 projectId，支持 preset、角色、分页和 idempotency。
P0	get_comic_generation_status	增强	返回结构化进度、预览、失败与可恢复动作。
P0	open_project	新增	返回可编辑项目 Deep Link。
P0	export_project	新增	导出 PDF、图片包或其他最终资产。
P1	update_panel / update_dialogue	新增	单格重绘、对白和局部修改。
P1	continue_story	新增	在既有角色与场景上下文中续写。
P1	create_character_bible	新增	生成并保存角色统一设定。
P2	translate_manga / comic_to_video	新增	扩展到本地化与视频化。

首批共享技能

story-to-comic

读取剧本或故事，识别角色与场景，创建项目，规划 Storyboard，生成面板，检查一致性并交付。

edit-comic-project

打开已有项目，定位面板，确认修改意图和 Credits，执行局部更新，验证新版本并返回项目链接。

工具命名、公开 mcp.json、Server Card、文档和实际路由必须由同一来源生成或在 CI 中做一致性校验。

任务规划与里程碑

以下为 2-3 名工程师并行推进的参考节奏；正式排期需要先完成第 0 阶段的产品决策。



阶段	主要任务	退出条件
Phase 0 方案冻结	确定首发宿主、MVP workflow、编辑器 Deep Link、Credits 规则、OAuth 方式、仓库归属。	PRD、工具契约、系统图、风险清单、验收用例。
Phase 1 平台 MVP	实现 OAuth 资源、最小 scopes、素材上传、create/open/export project、幂等和 Credits 确认。	端到端可从宿主创建项目并打开编辑器。
Phase 2 插件体验	建立 Codex 与 Claude 插件包，共享 story-to-comic 与 edit-comic-project 技能，完成安装和恢复指南。	两个宿主均可安装、登录、完成首个任务。
Phase 3 发布准备	上线两套落地页、3 个真实案例、FAQ、定价说明、漏斗埋点、灰度与回滚。	小流量 Beta，形成激活与成功率基线。
Phase 4 增长	增加角色 Bible、分镜、翻译、批量和视频技能；提交目录与市场；持续优化转化。	形成任务库和 Agent 分发渠道。

职责边界、验收与上线门槛

插件建设会跨越多个产品，但 API、数据与计费权威不应被复制到前端仓库。

归属	职责	边界
llamagen.ai	MCP 网关、OAuth、项目/素材/Credits API、公开安装页与文档。	权威后端与集成表面。
generate-server	模型调用、生成编排、重试、状态、参考素材限制。	生成执行层。
现有编辑器	项目查看、面板精修、版本、对白、导出。	不新造第二套编辑器。
新插件仓库	Codex/Claude manifest、共享技能、品牌资产、安装说明。	建议独立公开仓库；创建前单独确认。
oss.llamagen.ai	安装、OAuth、首个任务、Credits、错误与留存分析。	仅后台运营界面，不承载业务 API。

上线验收清单

- 全新用户可从一句安装指令开始，在 10 分钟内完成 OAuth 和第一次漫画项目创建。
- 宿主重试不会重复创建项目、生成任务或扣除 Credits。
- 每次消费前可看到估算；失败、取消与重试规则可解释。
- 生成任务可恢复；关闭宿主后再次打开仍能查询进度和项目。
- 最终响应同时包含成品资产、可编辑项目链接和任务摘要。
- ChatGPT/Codex 与 Claude Code 的 manifest、技能、工具名和文档通过自动一致性检查。
- 移动端/桌面端项目链接均可正确打开；无权限时返回明确登录或授权路径。
- 不运行生产迁移、CDN 上传或市场发布，直到 Beta 验收通过并获得明确授权。

指标、风险与会议结论模板

成功不以“插件安装了多少次”衡量，而以用户是否完成第一个可编辑项目衡量。

层级	指标	意义
获客	落地页 -> 复制安装指令	衡量页面价值表达。
安装	复制 -> 插件安装完成	衡量宿主和安装指南可靠性。
授权	安装 -> OAuth 成功	衡量登录摩擦。
激活	OAuth -> 首个项目成功	北极星前置指标。
价值	首个项目 -> 打开编辑器 / 导出	验证可编辑闭环。
质量	任务成功率、平均重试、结构化错误率	验证 Agent 和 MCP 稳定性。
商业	免费 Credits -> 付费或续费	验证插件渠道收入价值。

风险	级别	控制措施
OAuth/宿主兼容	高	先只支持明确版本；提供恢复指南和授权状态检查。
大文件上传	高	预签名 URL、大小/格式限制、断点或重试策略。
重复扣费	高	写工具幂等、消费前确认、任务状态机。
生成耗时	中	异步任务、可恢复查询、阶段进度、完成通知。
范围过大	高	MVP 只做两条工作流；其他能力放入 P1/P2。
表达误导	中	明确区分宿主推理用量、LlamaGen Credits 和编辑器跳转。

会议结论建议

若团队认可方向，会议结束时只需输出：首发宿主、两条 MVP 工作流、编辑器落点、账号/计费方案、技术负责人和 Beta 日期。其余细节进入 Phase 0 完成。

参考资料与说明

本方案基于 2026-07-23 至 2026-07-24 的页面浏览与 LlamaGen 本地工作区现状整理。

资料	地址	用途
ChatCut Claude Code Plugin	https://chatcut.io/claude-code-plugin	安装提示、任务案例、编辑器交付、定价与 FAQ。
ChatCut ChatGPT/Codex Plugin	https://chatcut.io/chatgpt-plugin	宿主安装、新任务切换、Agent 可执行安装协议。
ChatCut Agent Plugin	https://github.com/ChatCut-Inc/agent-plugin	Codex/Claude 双包、共享技能、托管 MCP 与 OAuth。
LlamaGen Comic API	https://llamagen.ai/comic-api	现有 Comic API、MCP、定价、Playground 与 ChatGPT/Claude 入口。
LlamaGen Comic API Docs	https://llamagen.ai/comic-api/docs	REST、MCP、认证、上传、状态、更新、SD K 和错误处理。
LlamaGen MCP Server Card	https://llamagen.ai/.well-known/mcp/server-card.json	现有 MCP 端点、认证与工具声明。

文档范围

这是产品与技术路线的内部讨论稿，不代表已经获得插件市场、OAuth 生产配置、CDN 上传、数据库迁移或正式发布授权。正式实施前应按照 LlamaGen 各子仓库的本地指导确认实际代码归属与验证命令。

建议下一步

召开 45 分钟立项会：15 分钟确认产品定位，15 分钟确认技术边界，10 分钟确认 MVP 和负责人，5 分钟确定 Beta 日期。